MC-SD01-I

Introdução ao ambiente SDUMONT/SLURM

Escola Santos Dumont
11 de Janeiro 2021
LNCC
evento online

Laboratório Nacional de Computação Científica

A máquina

Mobull - solução para datacenter baseada em containers.

Plug & Boot

2 containers com 22 racks 42U

A máquina

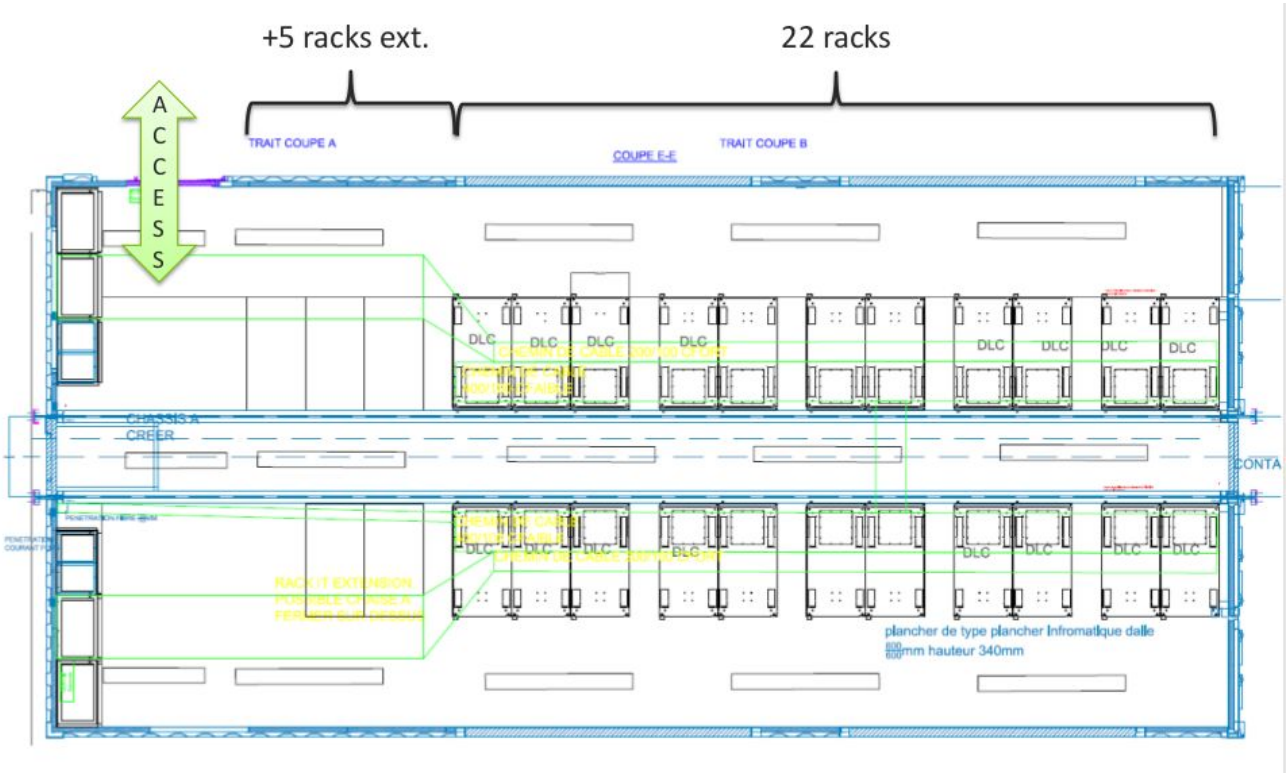
+5 racks ext.
22 racks
ACCESS
TRAIT COUPE A
COUPE E-E
TRAIT COUPE B
DLC
CHASSIS A CREER
plancher de type plancher Infromatique dalle
mm hauteur 340mm

Arquitetura

Cluster de propósito geral

3 tipos de nodes:

- thin nodes
- hybrid nodes
- fat-node

Arquitetura

Thin nodes (B710)

- 7 racks completos (504 nós computacionais)
- 2 nós computacionais por blade
- Configuração
  - 2x Intel Xeon E5-2695v2 (12c, 2.4Ghz)
  - 64 GB DDR3 RAM (8x 8GB DIMM)
  - 1x 120GB SSD disk
  - 1x Infiniband FDR ConnectX3
  - 1x GbE

Arquitetura

Thin nodes (Bull Sequana) - Machine Learning/Deep Learning

- 1 nó computacional
- Configuração
  - 2x Intel Skylake GOLD 6148, 2,4Ghz (20c)
  - 384 GB DDR4
  - 4x Infiniband EDR 100Gbps
  - 8x NVidia V100 com NVLink

Arquitetura

Hybrid nodes (B715)

- 7 racks completos (252 nós computacionais e 504 aceleradores)
- 198 nodes e 396 nVidia K40
- 54 nodes e 108 Intel Phi 7120P

Arquitetura

Fat-node (S6130)

- 16x Intel Ivy Bridge E7 2870v2 15c 2.3Ghz
- 6TB DDR3 RAM
- 1x 120GB SSD disk
- 1x Infiniband FDR ConnectX3
- 1x GbE

Arquitetura

Login nodes

- 4x bullx R423-E3
- Linux Virtual Server (LVS)
- Cada login node possui:
  - 2x E5-2695v2 12c, 2.4GHz
  - 128 GB DDR3@1866RAM
  - 2x 500GB 7.2krpm SATA2 RAID1
  - 1x GbE network port
  - 1x IB FDR network port
  - 1x Ethernet BMC network port
  - 2x 10GbE network ports

Arquitetura

Armazenamento

- Lustre - Seagate ClusterStor 9000
  - Total 1,7 Petabytes
- DellEMC Isilon
  - Total 650 Terabytes

Estrutura de diretórios

Diretório home ($HOME):

- NFS
- Acessível apenas nos login nodes
- /prj/NOME_PROJETO/login.name

Diretório de scratch ($SCRATCH):

- Lustre
- Acessível a todos os nodes do cluster
- /scratch/NOME_PROJETO/login.name

Desempenho

- GPU - 456,8 TFlop/s
- PHI - 363,2 TFlop/s
- CPU - 321,2 TFlop/s
- Total - 1.141,2 TFlop/s

TOP 500	Total	GPU	PHI	CPU
Jun/15	55	145	177	207
Nov/15	63	200	265	310
Jun/16	75	265	364	433
Nov/16	91	364	476	
Jun/17	107	472		
Nov/17	128			
Jun/18	192			
Nov/18	316			

https://www.top500.org

Expansão SDumont

- 1 Célula Sequana X1000 CPU
  - 82 Blades X1120 - 384 GB
  - 12 Blades X1120 - 768 GB
  - 282 nós computacionais
  - 2x Intel CascadeLake Gold 6252 (24c)

- 1 Célula Sequena X1000 GPU
  - 94 Blades X1125 - 384 GB
  - 1 nó computacional e 4 aceleradores NVIDIA Volta V100 GPU por blade
  - 2x Intel CascadeLake Gold 6252 (24c)

Expansão SDumont

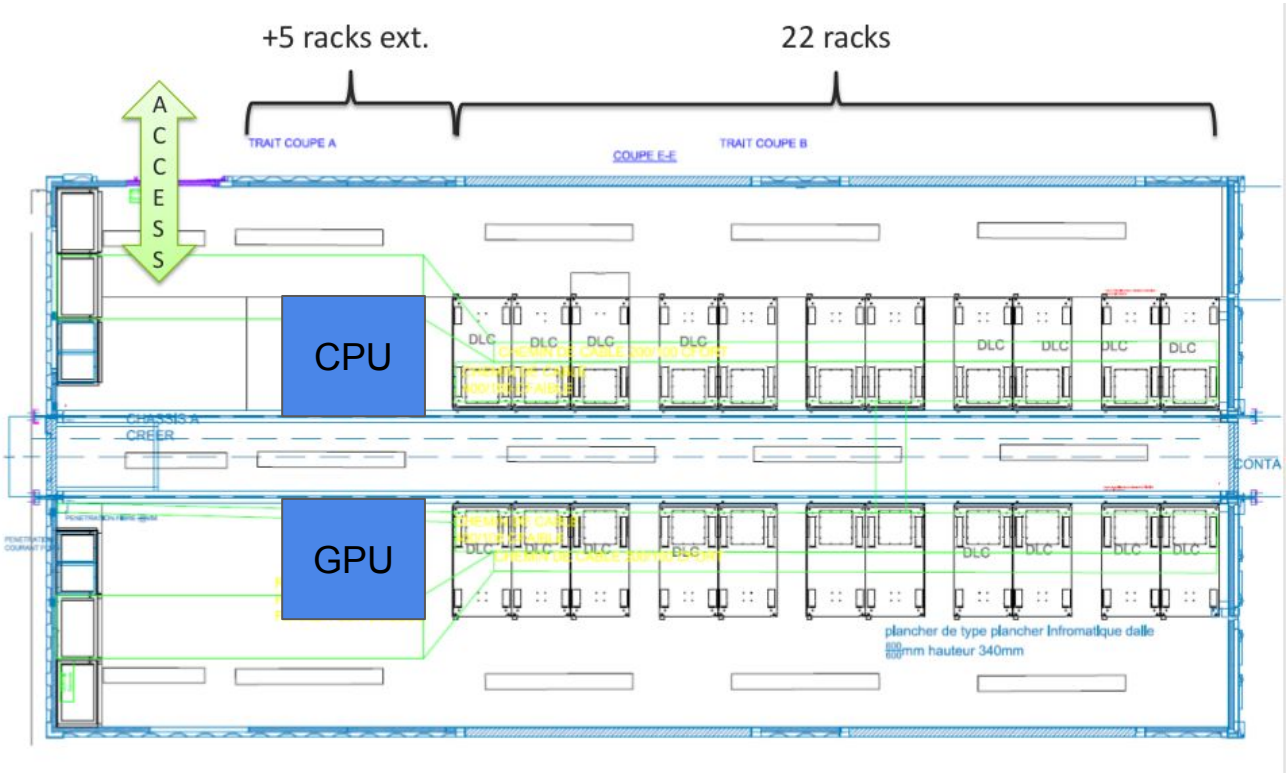

Laboratório Nacional de Computação Científica

Desempenho

Novembro 2019

193	Laboratório Nacional de Computação Científica Brazil	**Santos Dumont (SDumont)** - Bull Sequana X1000, Xeon Gold 6252 24C 2.1GHz, Mellanox InfiniBand EDR, NVIDIA Tesla V100 SXM2 Atos	33,856	1,849.0	2,727.0

Junho 2020

240	**Santos Dumont (SDumont)** - Bull Sequana X1000, Xeon Gold 6252 24C 2.1GHz, Mellanox InfiniBand EDR, NVIDIA Tesla V100 SXM2, Atos Laboratório Nacional de Computação Científica Brazil		33,856	1,849.0	2,727.0

Novembro 2020

276	**Santos Dumont (SDumont)** - Bull Sequana X1000, Xeon Gold 6252 24C 2.1GHz, Mellanox InfiniBand EDR, NVIDIA Tesla V100 SXM2, Atos Laboratório Nacional de Computação Científica Brazil		33,856	1,849.0	2,727.0

Filas

Filas	Wall-clock	Nodes	Núcleos	Execução	Na fila
treinamento_gpu	**30min**	**2**	**48**	**1**	**2**
treinamento	**30min**	**1 - 4**	**96**	**1**	**2**

Módulos de ambiente

module avail

module whatis/help

module load

module unload

module list

Intel Parallel Studio

source /scratch/app/modulos/intel-psxe-20[16|17|18|19|20].sh

Compiladores

GNU

Versões: 4.8.5, 6.5, 7.4 e 8.3

INTEL

Versões: 2016, 2017, 2018, 2019 e 2020

PGI

Versão 2016.5 e 2019.10 (Community)

Implementações MPI

OpenMPI (Bull)

Versão 2.0.4 - Implementação MPI compilada pela Bull

OpenMPI

Versões: 2.0.4, 3.1.4 e 4.0.1

Intel MPI

Versões 5.1, 2016, 2017, 2018, 2019 e 2020

Slurm

Versão 17.02

Onde encontrar referências?

http://sdumont.lncc.br/

https://slurm.schedmd.com/archive/slurm-17.02.11

Política de escalonamento

Backfill: prioridade, tempo na fila, quantidade de memória e etc.

Acesso

Somente os alunos que já possuem conta no SDumont poderão acessar o ambiente.

```
$ ssh meu.login@login.sdumont.lncc.br
```

Não serão distribuídas credenciais para os demais usuários.

SLURM: comandos básicos

- **sinfo:** visualiza informação sobre os nós e partições do SLURM
- **squeue:** visualiza informação sobre o status dos jobs e escalonamento
- **srun:** alocação de recursos e distribuição de tarefas
- **scontrol:** ferramenta para visualizar e/ou modificar o estado de um job
- **salloc:** obtém uma alocação para o job
- **sbatch:** submete um script para alocação em uma partição do SLURM
- **scancel:** cancela um job
- **sacct:** mostra informação de jobs já submetidos

Comandos básicos

sinfo

```
$ sinfo -s

PARTITION       AVAIL  TIMELIMIT   NODES(A/I/O/T)  NODELIST
treinamento        up   infinite        0/10/0/10  sdumont[5000-5009]
treinamento_gpu    up   infinite          0/2/0/2  sdumont[3000-3001]
```

Comandos básicos

sinfo

```
$ sinfo -s

PARTITION       AVAIL  TIMELIMIT   NODES(A/I/O/T)  NODELIST
cpu*               up   infinite    350/229/7/586  sdumont[1000-1503,3110-3159,5012-5043]
nvidia             up   infinite     119/71/2/192  sdumont[3006-3197]
phi                up   infinite       13/19/0/32  sdumont[5012-5043]
mesca2             up   infinite          0/1/0/1  sdumont57
cpu_small          up   infinite    350/229/7/586  sdumont[1000-1503,3110-3159,5012-5043]
nvidia_small       up   infinite     119/71/2/192  sdumont[3006-3197]
cpu_dev            up   infinite    287/220/7/514  sdumont[1000-1503,5044-5053]
nvidia_dev         up   infinite     119/71/2/192  sdumont[3006-3197]
phi_dev            up   infinite       13/19/0/32  sdumont[5012-5043]
cpu_scal           up   infinite    350/229/7/586  sdumont[1000-1503,3110-3159,5012-5043]
cpu_long           up   infinite    300/229/7/536  sdumont[1000-1503,5012-5043]
nvidia_scal        up   infinite     119/71/2/192  sdumont[3006-3197]
nvidia_long        up   infinite     119/71/2/192  sdumont[3006-3197]
all             inact 2-00:00:00    419/328/9/756  sdumont[1000-1503,3000-3197,5000-5053]
treinamento        up   infinite       0/10/0/10  sdumont[5000-5009]
treinamento_gpu    up   infinite          0/2/0/2  sdumont[3000-3001]
```

Comandos básicos

sinfo

Outras opções:

- -s
- --long
- --state
- -R

Comandos básicos

squeue

Outras opções

- -s
- -u (user)
- -A (account)
- -p

Comandos básicos

squeue

```
$ squeue

JOBID PARTITION     NAME     USER ST       TIME  NODES NODELIST(REASON)
 1767       cpu mpiblast  labinfo  R    9:40:13      1 sdumont1128
 1769       cpu mpiblast  labinfo  R    9:35:10      1 sdumont1130
 1770       cpu mpiblast  labinfo  R    9:33:36      2 sdumont[1000-1001]
 1772       cpu mpiblast  labinfo  R    9:29:48      2 sdumont[1106-1107]
 1777       cpu brams-5. xrpsouto  R    1:12:10      1 sdumont1126
 1776    mesca2 TEST_bla  labinfo  R    8:21:18      1 sdumont57
```

SLURM: comandos básicos

- **sinfo:** visualiza informação sobre os nós e partições do SLURM
- **squeue:** visualiza informação sobre o status dos jobs e escalonamento
- **srun:** alocação de recursos e distribuição de tarefas
- **scontrol:** ferramenta para visualizar e/ou modificar o estado de um job
- **salloc:** obtém uma alocação para o job
- **sbatch:** submete um script para alocação em uma partição do SLURM
- **scancel:** cancela um job
- **sacct:** mostra informação de jobs já submetidos

Comandos básicos

srun

```
$ srun --nodes=3 --ntasks=15
```

Alocação de recursos computacionais (“CPUs”:*sockets*/núcleos) a partir de um conjunto de nós.

Node	n0	n1	n2
Allocate CPUS:	8	6	1

Alocação padrão dos nós é por blocos (***block***): o recurso é alocado em um nó, de modo que os recursos consecutivos estejam neste mesmo nó.

Outro método de alocação é o cíclico (***cyclic***): o recurso é alocado em um nós, de modo que os recursos consecutivos sejam alocados em nós consecutivos (escalonamento *round-robin*)

Comandos básicos

srun

```
$ srun --ntasks=6
```

Alocação de recursos computacionais a partir de um conjunto de *sockets*, dentro de um nó.
Neste exemplo, um nó com 2 *sockets*, com 4 núcleos cada.

Socket	0	1
Allocate CPUS:	3	3

O método de alocação padrão aqui é o cíclico (***cyclic***): o recurso é atribuído para um *socket*, de modo que os recursos consecutivos sejam alocados em *sockets* consecutivos.

Outro método de alocação é por blocos (***block***): o recurso é atribuído para um *socket*, de modo que os tarefas consecutivos sejam alocados neste mesmo *socket*.

Comandos básicos

srun

```
$ srun --nodes=3 --ntasks=8 --cpus-per-task=2
```

Distribuição das **tarefas** entre os recursos computacionais (“CPUs”:*sockets*/núcleos) alocados.
Ne a.

Node	n0	n1	n2
Allocate CPUS:	8	6	2
Distribution	0-3	4-6	7

Distribuição padrão aqui é por blocos (***block***): a tarefa é atribuída para um recurso, de modo que as tarefas consecutivas sejam atribuídas para este mesmo recurso.

Outro método de distribuição é a cíclica (***cyclic***): a tarefa é atribuída para um recurso, de modo que as tarefas consecutivas sejam distribuídas no recursos consecutivos (escalonamento *round-robin*)

Comandos básicos

srun

```
$ srun --ntasks=8 --cpu_bind=cores
```

Distribuição de tarefas para os recursos alocados dentro de um nó.

Node	n0							
Socket#	0				1			
CPI#	0	1	2	3	4	5	6	7
Bounds Task#	0	2	4	6	1	3	5	7

Distribuição padrão aqui é a <u>cíclica</u> (***cyclic***): a tarefa é atribuída para um *socket*, de modo que as tarefas consecutivas sejam distribuídas em núcleos de *sockets* consecutivos.

Outro método de distribuição é por <u>blocos</u> (***block***): a tarefa é atribuída para um *socket*, de modo que as tarefas consecutivas utilizem os núcleos deste mesmo *socket*.

Mapeamento (*mapping*) e vinculação (*binding*)

Mapping define como as tarefas são distribuídas:
- no nível de núcleos
- no nível de sockets
- no nível de nós

Binding define a afinidade das tarefas:
- por núcleo
- por socket
- por nó (sem *binding*)

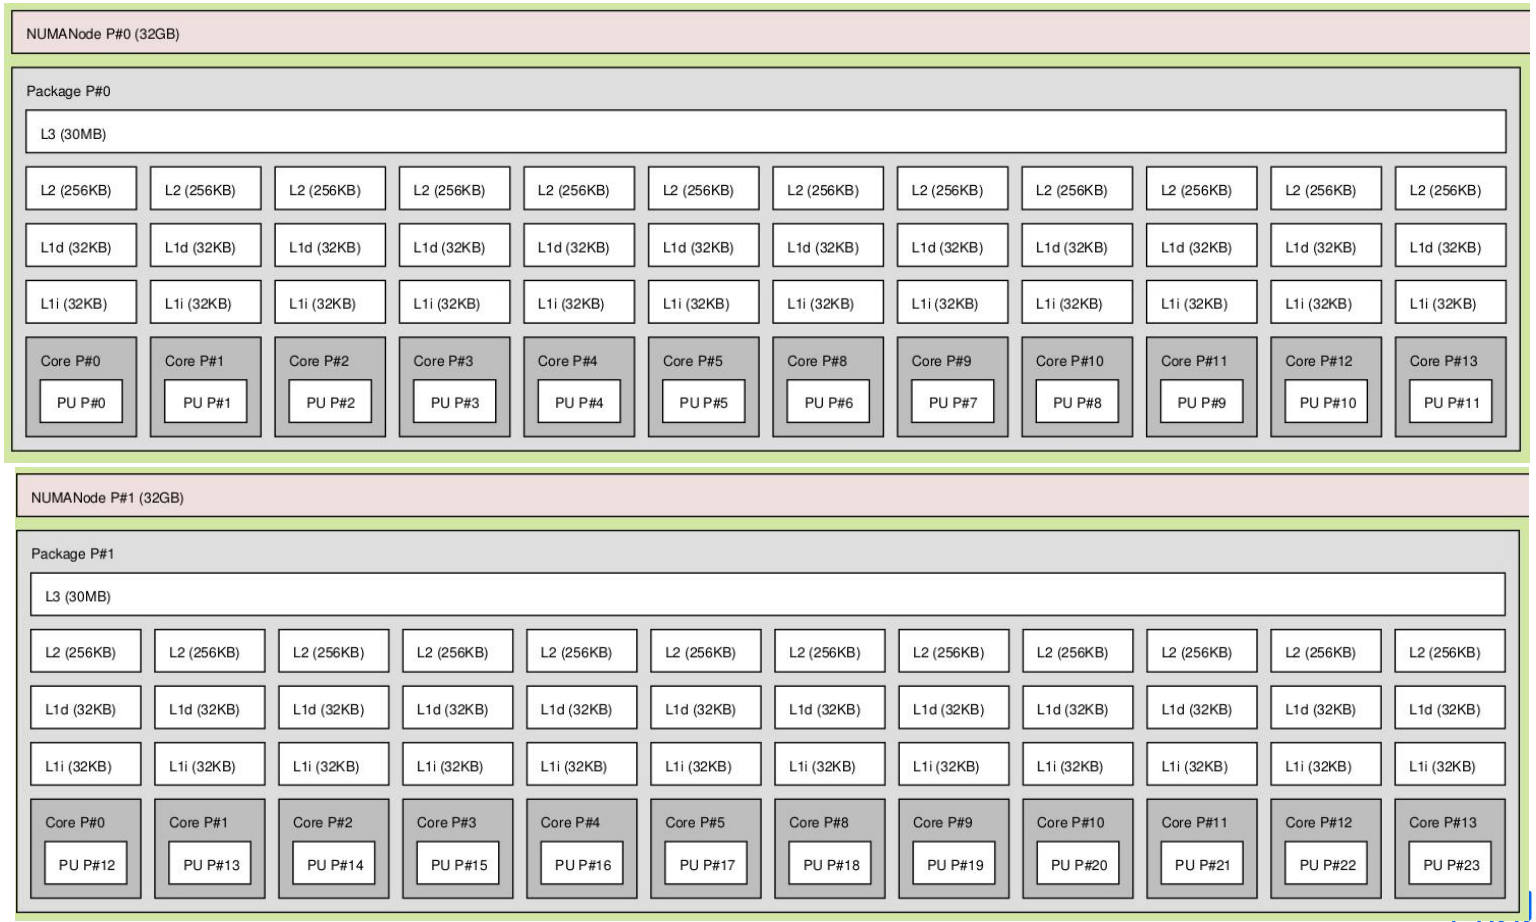
NUMANode P#0 (32GB)
Package P#0
L3 (30MB)
L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB)
L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB)
L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB)
Core P#0 PU P#0
Core P#1 PU P#1
Core P#2 PU P#2
Core P#3 PU P#3
Core P#4 PU P#4
Core P#5 PU P#5
Core P#8 PU P#6
Core P#9 PU P#7
Core P#10 PU P#8
Core P#11 PU P#9
Core P#12 PU P#10
Core P#13 PU P#11
NUMANode P#1 (32GB)
Package P#1
L3 (30MB)
L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB) L2 (256KB)
L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB) L1d (32KB)
L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB) L1i (32KB)
Core P#0 PU P#12
Core P#1 PU P#13
Core P#2 PU P#14
Core P#3 PU P#15
Core P#4 PU P#16
Core P#5 PU P#17
Core P#8 PU P#18
Core P#9 PU P#19
Core P#10 PU P#20
Core P#11 PU P#21
Core P#12 PU P#22
Core P#13 PU P#23

`srun`: distribuição das tarefas

```
$ srun -p treinamento --nodes=3 --ntasks=6 --cpus-per-task=8 sleep 60

$ squeue
             JOBID PARTITION     NAME     USER ST       TIME  NODES NODELIST(REASON)
            159893 treinamen    sleep professo  R       0:10      3 sdumont[5000-5002]

$ scontrol --details show job 159893

   NumNodes=3 NumCPUs=48 CPUs/Task=8 ReqB:S:C:T=0:0:*:*
   Nodes=sdumont5000 CPU_IDs=0-23 Mem=64000
   Nodes=sdumont5001 CPU_IDs=0-15 Mem=64000
   Nodes=sdumont5002 CPU_IDs=0-7 Mem=64000
```

srun: distribuição das tarefas

```
$ srun -p treinamento       -N3        -n6              -c8 sleep 60 (forma compacta)

$ squeue
             JOBID PARTITION     NAME     USER ST       TIME  NODES NODELIST(REASON)
            159893 treinamen    sleep professo  R       0:10      3 sdumont[5000-5002]

$ scontrol --details show job 159893

   NumNodes=3 NumCPUs=48 CPUs/Task=8 ReqB:S:C:T=0:0:*:*
   Nodes=sdumont5000 CPU_IDs=0-23 Mem=64000
   Nodes=sdumont5001 CPU_IDs=0-15 Mem=64000
   Nodes=sdumont5002 CPU_IDs=0-7 Mem=64000
```

`srun`: distribuição das tarefas

```
$ scontrol --details show job 159893
JobId=159893 JobName=sleep
   UserId=professor(63001) GroupId=treinamento(61052)
   Priority=1791 Nice=0 Account=treinamento QOS=normal
   JobState=RUNNING Reason=None Dependency=(null)
   Requeue=1 Restarts=0 BatchFlag=0 Reboot=0 ExitCode=0:0
   DerivedExitCode=0:0
   RunTime=00:00:27 TimeLimit=00:10:00 TimeMin=N/A
   SubmitTime=2018-02-25T07:54:18 EligibleTime=2018-02-25T07:54:18
   StartTime=2018-02-25T07:54:18 EndTime=2018-02-25T08:04:18
   PreemptTime=None SuspendTime=None SecsPreSuspend=0
   Partition=treinamento AllocNode:Sid=sdumont13:28904
   ReqNodeList=(null) ExcNodeList=(null)
   NodeList=sdumont[5000-5002]
   BatchHost=sdumont5000
   NumNodes=3 NumCPUs=48 CPUs/Task=8 ReqB:S:C:T=0:0:*:*
   Socks/Node=* NtasksPerN:B:S:C=0:0:*:* CoreSpec=*
     Nodes=sdumont5000 CPU_IDs=0-23 Mem=64000
     Nodes=sdumont5001 CPU_IDs=0-15 Mem=64000
     Nodes=sdumont5002 CPU_IDs=0-7 Mem=64000
   MinCPUsNode=8 MinMemoryNode=62.50G MinTmpDiskNode=0
   Features=(null) Gres=(null) Reservation=(null)
   Shared=OK Contiguous=0 Licenses=(null) Network=(null)
   Command=sleep
   WorkDir=/prj/treinamento/professor
```

`srun`: distribuição das tarefas

```
$ srun -p treinamento -N3 -n6 -c8 -m block:cyclic --cpu_bind=cores,verbose sleep 1

cpu_bind=MASK - sdumont5000, task  0  0 [18472]: mask 0xff set
cpu_bind=MASK - sdumont5000, task  1  1 [18473]: mask 0xff000 set
cpu_bind=MASK - sdumont5000, task  2  2 [18474]: mask 0xf00f00 set
cpu_bind=MASK - sdumont5001, task  3  0 [41701]: mask 0xff set
cpu_bind=MASK - sdumont5001, task  4  1 [41702]: mask 0xff000 set
cpu_bind=MASK - sdumont5002, task  5  0 [88601]: mask 0xff set
```

método de distribuição das tarefas entre os núcleos
-m [node:socket] ou --distribuition[node:socket]

`srun`: distribuição das tarefas

```
$ srun -p treinamento -N3 -n6 -c8 -m cyclic:cyclic --cpu_bind=cores,verbose sleep 1

cpu_bind=MASK - sdumont5000, task  0  0 [18543]: mask 0xff set
cpu_bind=MASK - sdumont5001, task  1  0 [41762]: mask 0xff set
cpu_bind=MASK - sdumont5002, task  2  0 [88656]: mask 0xff set
cpu_bind=MASK - sdumont5000, task  3  1 [18544]: mask 0xff000 set
cpu_bind=MASK - sdumont5001, task  4  1 [41763]: mask 0xff000 set
cpu_bind=MASK - sdumont5000, task  5  2 [18545]: mask 0xf00f00 set
```

`srun`: distribuição das tarefas

```
$ srun -p treinamento -N3 -n6 -c8 -m block:cyclic --cpu_bind=cores,verbose
--label cat /proc/self/status | grep Cpus_allowed_list | grep Cpus_allowed_list

0: cpu_bind=MASK - sdumont5000, task  0  0 [18849]: mask 0xff set
1: cpu_bind=MASK - sdumont5000, task  1  1 [18850]: mask 0xff000 set
2: cpu_bind=MASK - sdumont5000, task  2  2 [18851]: mask 0xf00f00 set
3: cpu_bind=MASK - sdumont5001, task  3  0 [42038]: mask 0xff set
4: cpu_bind=MASK - sdumont5001, task  4  1 [42039]: mask 0xff000 set
5: cpu_bind=MASK - sdumont5002, task  5  0 [88908]: mask 0xff set

0: Cpus_allowed_list:    0-7
1: Cpus_allowed_list:    12-19
2: Cpus_allowed_list:    8-11,20-23
3: Cpus_allowed_list:    0-7
4: Cpus_allowed_list:    12-19
5: Cpus_allowed_list:    0-7
```

`srun`: distribuição das tarefas

```
$ srun -p treinamento -N3 -n6 -c8 -m block:cyclic --cpu_bind=cores,verbose
--label cat /proc/self/status | grep Cpus_allowed_list | grep Cpus_allowed_list

0: cpu_bind=MASK - sdumont5000, task  0  0 [18849]: mask 0xff set
1: cpu_bind=MASK - sdumont5000, task  1  1 [18850]: mask 0xff000 set
2: cpu_bind=MASK - sdumont5000, task  2  2 [18851]: mask 0xf00f00 set
3: cpu_bind=MASK - sdumont5001, task  3  0 [42038]: mask 0xff set
4: cpu_bind=MASK - sdumont5001, task  4  1 [42039]: mask 0xff000 set
5: cpu_bind=MASK - sdumont5002, task  5  0 [88908]: mask 0xff set

0: Cpus_allowed_list:    0-7
1: Cpus_allowed_list:    12-19
2: Cpus_allowed_list:    8-11,20-23 (diferentes sockets)
3: Cpus_allowed_list:    0-7
4: Cpus_allowed_list:    12-19
5: Cpus_allowed_list:    0-7
```

`srun`: distribuição das tarefas

```
$ srun -p treinamento -N3 -n6 -c8 -m block:block  --cpu_bind=cores,verbose
--label cat /proc/self/status | grep Cpus_allowed_list | grep Cpus_allowed_list

0: cpu_bind=MASK - sdumont5000, task  0  0 [19142]: mask 0xff set
1: cpu_bind=MASK - sdumont5000, task  1  1 [19143]: mask 0xff00 set
2: cpu_bind=MASK - sdumont5000, task  2  2 [19144]: mask 0xff0000 set
3: cpu_bind=MASK - sdumont5001, task  3  0 [42305]: mask 0xff set
4: cpu_bind=MASK - sdumont5001, task  4  1 [42306]: mask 0xff00 set
5: cpu_bind=MASK - sdumont5002, task  5  0 [89156]: mask 0xff set

0: Cpus_allowed_list:    0-7
1: Cpus_allowed_list:    8-15
2: Cpus_allowed_list:    16-23 (mesmo socket)
3: Cpus_allowed_list:    0-7
4: Cpus_allowed_list:    8-15
5: Cpus_allowed_list:    0-7
```

`srun`: distribuição das tarefas

```
$ srun -p treinamento -N3 -n6 -c8 -m block:block  --cpu_bind=socket,verbose
--label cat /proc/self/status | grep Cpus_allowed_list | grep Cpus_allowed_list

0: cpu_bind=MASK - sdumont5000, task  0  0 [19301]: mask 0xfff set
1: cpu_bind=MASK - sdumont5000, task  1  1 [19302]: mask 0xffffff set
2: cpu_bind=MASK - sdumont5000, task  2  2 [19303]: mask 0xfff000 set
3: cpu_bind=MASK - sdumont5001, task  3  0 [42454]: mask 0xfff set
4: cpu_bind=MASK - sdumont5001, task  4  1 [42455]: mask 0xffff set
5: cpu_bind=MASK - sdumont5002, task  5  0 [89293]: mask 0xff set

0: Cpus_allowed_list:    0-11
1: Cpus_allowed_list:    0-23 (sem garantia de ser no mesmo socket)
2: Cpus_allowed_list:    12-23
3: Cpus_allowed_list:    0-11
4: Cpus_allowed_list:    0-15
5: Cpus_allowed_list:    0-7
```

`srun`: distribuição das tarefas

```
$ srun -p treinamento -N3 -n6 -c8 -m block:cyclic --cpu_bind=socket,verbose
--label cat /proc/self/status | grep Cpus_allowed_list | grep Cpus_allowed_list

0: cpu_bind=MASK - sdumont5000, task  0  0 [18982]: mask 0xfff set
1: cpu_bind=MASK - sdumont5000, task  1  1 [18983]: mask 0xfff000 set
2: cpu_bind=MASK - sdumont5000, task  2  2 [18984]: mask 0xffffff set
3: cpu_bind=MASK - sdumont5001, task  3  0 [42155]: mask 0xff set
4: cpu_bind=MASK - sdumont5001, task  4  1 [42156]: mask 0xff000 set
5: cpu_bind=MASK - sdumont5002, task  5  0 [89018]: mask 0xff set

0: Cpus_allowed_list:    0-11
1: Cpus_allowed_list:    12-23
2: Cpus_allowed_list:    0-23
3: Cpus_allowed_list:    0-7
4: Cpus_allowed_list:    12-19
5: Cpus_allowed_list:    0-7
```

`srun`: distribuição das tarefas

```
$ srun -p treinamento -N1 -n24 -c1 -m block:cyclic --cpu_bind=cores,verbose
--label cat /proc/self/status | grep Cpus_allowed_list | grep Cpus_allowed_list
00:   Cpus_allowed_list:        0
01:   Cpus_allowed_list:       12
02:   Cpus_allowed_list:        1
03:   Cpus_allowed_list:       13
04:   Cpus_allowed_list:        2
05:   Cpus_allowed_list:       14
06:   Cpus_allowed_list:        3
07:   Cpus_allowed_list:       15
08:   Cpus_allowed_list:        4
09:   Cpus_allowed_list:       16
10:   Cpus_allowed_list:        5
11:   Cpus_allowed_list:       17
12:   Cpus_allowed_list:        6
13:   Cpus_allowed_list:       18
14:   Cpus_allowed_list:        7
15:   Cpus_allowed_list:       19
16:   Cpus_allowed_list:        8
17:   Cpus_allowed_list:       20
18:   Cpus_allowed_list:        9
19:   Cpus_allowed_list:       21
20:   Cpus_allowed_list:       10
21:   Cpus_allowed_list:       22
22:   Cpus_allowed_list:       11
23:   Cpus_allowed_list:       23
```

Exemplo: NAS Parallel Benchmark (BT-MZ)

```
$ tar xvf MC-SD01-I.tar
$ cd MC-SD01-I/openmpi/gnu/NPB3.3.1-MZ/
$ ls -A1
  Changes.log
  env_openmpi
  NPB3.3-MZ-MPI
  NPB3.3-MZ-OMP
  NPB3.3-MZ-SER
  README
$ cat env_openmpi
module load openmpi/gnu/2.0.4.2
$ source env_openmpi
$ mpicc -show
gcc -I/opt/mpi/openmpi-gnu/2.0.4.2/include -pthread -L/opt/mpi/openmpi-gnu/2.0.4.2/lib
-lmpi
```

Exemplo: NAS Parallel Benchmark (BT-MZ)

```
$ cd NPB3.3-MZ-MPI/config/
$ ls -A1
  make.def
  make.def.template
  NAS.samples/
  suite.def
  suite.def.template
$ cat make.def
```

Exemplo: NAS Parallel Benchmark (BT-MZ)

```
$ cat suite.def

# config/suite.def
# This file is used to build several benchmarks with a single command.
# Typing "make suite" in the main directory will build all the benchmarks
# specified in this file.
# Each line of this file contains a benchmark name, class, and number
# of nodes. The name is one of "sp-mz", "bt-mz", and "lu-mz".
# The class is one of "S", "W", and "A" through "F".
# No blank lines.
# The following example builds serial sample sizes of all benchmarks.
#sp-mz     S    1
#lu-mz     S    1
#bt-mz     S    1
bt-mz      W    1
bt-mz      W    2
bt-mz      W    4
bt-mz      A    1
```

Exemplo: NAS Parallel Benchmark (BT-MZ)

```
$ cd ../
$ pwd
  ../MC-SD01-I/openmpi/gnu/NPB3.3.1-MZ/NPB3.3-MZ-MPI
$ make suite --> compila o bechmark BT-MZ
$ cd bin
$ ls -A1
bt-mz.W.1
bt-mz.W.16
bt-mz.W.2
bt-mz.W.4
bt-mz.W.8
BULL_srun_openmpi.sh
```

SLURM: comandos básicos

- **sinfo:** visualiza informação sobre os nós e partições do SLURM
- **squeue:** visualiza informação sobre o status dos jobs e escalonamento
- **srun:** alocação de recursos e distribuição de tarefas
- **scontrol:** ferramenta para visualizar e/ou modificar o estado de um job
- **salloc:** obtém uma alocação para o job
- **sbatch:** submete um script para alocação em uma partição do SLURM
- **scancel:** cancela um job
- **sacct:** mostra informação de jobs já submetidos

Exemplo: NAS Parallel Benchmark (BT-MZ)

```
$ srun -p treinamento -N1 -n1 ./bt-mz.W.1  --> submete o job com srun

-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas

$ salloc -p treinamento -N1 -n1  mpirun ./bt-mz.W.1     --> submete o job com salloc
salloc: Granted job allocation 105518

 Class           =                        W
 Size            =             64x   64x  8
 Iterations      =                      200
 Time in seconds =                     5.82
 Total processes =                        1
 Total threads   =                        1
 Mop/s total     =                  2464.61
 Mop/s/thread    =                  2464.61
salloc: Relinquishing job allocation 105518
salloc: Job allocation 105518 has been revoked.
```

Exemplo: NAS Parallel Benchmark (BT-MZ)

```
$ salloc -p treinamento -N1 -n2  mpirun ./bt-mz.W.2      --> submete o job com salloc
salloc: Granted job allocation 105519
Class            =                        W
 Size            =             64x   64x  8
 Iterations      =                     200
 Time in seconds =                    2.96
 Total processes =                       2
 Total threads   =                       2
 Mop/s total     =                 4851.15
 Mop/s/thread    =                 2425.57

salloc: Relinquishing job allocation 105519
salloc: Job allocation 105519 has been revoked.
```

Exemplo: NAS Parallel Benchmark (BT-MZ)

```
$ srun -p treinamento -N1 -n2      ./bt-mz.W.2      --> submete o job com srun

Class           =                        W
 Size           =              64x   64x  8
 Iterations     =                      200
 Time in seconds =                    2.96
 Total processes =                       2
 Total threads   =                       2
 Mop/s total     =                 4851.15
 Mop/s/thread    =                 2425.57
```

Exemplo: NAS Parallel Benchmark (BT-MZ)

```
$ srun -p treinamento -N1 -n1 -c2 ./bt-mz.W.1 --> para execução multi-thread

-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
-c2 (--cpus-per-task=2): define o número de cpus por tarefa (MPI rank)

BT-MZ Benchmark Completed.
 Class           =                        W
 Size            =             64x   64x  8
 Iterations      =                      200
 Time in seconds =                     5.85  --> desempenho aquém do esperado
 Total processes =                        1
 Total threads   =                        1
```

Exemplo: NAS Parallel Benchmark (BT-MZ)

```
$ srun -p treinamento -N1 -n1 -c2 ./bt-mz.W.1 --> para execução multi-thread

-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
-c2 (--cpus-per-task=2): define o número de cpus por tarefa (MPI rank)

BT-MZ Benchmark Completed.
 Class           =                        W
 Size            =              64x   64x  8
 Iterations      =                      200
 Time in seconds =                     5.85  --> definir var. de amb. OMP_NUM_THREADS
 Total processes =                        1
 Total threads   =                        1

$ export OMP_NUM_THREADS=2 --> (igual a --cpus-per-task)
```

Exemplo: NAS Parallel Benchmark (BT-MZ)

```
$ srun -p treinamento -N1 -n1 -c2 ./bt-mz.W.1 --> para execução multi-thread

-N1 (--nodes=1): define o número de nós a serem alocados
-n1 (--ntasks=1): define o número total de tarefas (MPI ranks) a serem executadas
-c2 (--cpus-per-task=2): define o número de cpus por tarefa (MPI rank)

BT-MZ Benchmark Completed.
 Class           =                        W
 Size            =             64x   64x  8
 Iterations      =                      200
 Time in seconds =                     3.03 --> redução de tempo
 Total processes =                        1
 Total threads   =                        2
```

SLURM: comandos básicos

- **sinfo:** visualiza informação sobre os nós e partições do SLURM
- **squeue:** visualiza informação sobre o status dos jobs e escalonamento
- **srun:** alocação de recursos e distribuição de tarefas
- **scontrol:** ferramenta para visualizar e/ou modificar o estado de um job
- **salloc:** obtém uma alocação para o job
- **sbatch:** submete um script para alocação em uma partição do SLURM
- **scancel:** cancela um job
- **sacct:** mostra informação de jobs já submetidos

SLURM: comandos básicos

sbatch

- parâmetros na linha de comando
- parâmetros no script

principais opções de configuração:
--time (-t)
--nodes (-N)
--ntasks (-n)
--ntasks-per-node
--cpus-per-task (-c)
--partition (-p)

Exemplo: NAS Parallel Benchmark (BT-MZ)

BULL_srun_openmpi.sh

```
#!/bin/bash

#SBATCH --nodes=1                       # here the number of nodes
#SBATCH --ntasks=1                      # here total number of mpi tasks
#SBATCH --cpus-per-task=1               # number of cores per node
#SBATCH -p treinamento              # target partition
#SBATCH -J NPB_BT-MZ                        # job name
#SBATCH --time=00:05:00                 # time limit
#SBATCH --exclusive                     # to have exclusive use of your nodes

echo "Cluster configuration:"
echo "==="
echo "Partition: " $SLURM_JOB_PARTITION
echo "Number of nodes: " $SLURM_NNODES
echo "Number of MPI processes: " $SLURM_NTASKS " (" $SLURM_NNODES " nodes)"
echo "Number of MPI processes per node: " $SLURM_NTASKS_PER_NODE
echo "Number of threads per MPI process: " $SLURM_CPUS_PER_TASK
echo "NPB Benchmark: " $1
echo "Bechmark class problem: " $2
```

Exemplo: NAS Parallel Benchmark (BT-MZ)

BULL_srun_openmpi.sh (cont.)

```
###################################
#           COMPILER              #
###################################
module load openmpi/gnu/2.0.4.2

DIR=$PWD

bench=${1}
class=${2}
execfile="${bench}.${class}.$SLURM_NTASKS"
BIN=$DIR/${execfile}

export OMP_NUM_THREADS=$SLURM_CPUS_PER_TASK

cd $DIR

srun -n $SLURM_NTASKS $BIN

dirdest="${bench}_${class}_MPI-${SLURM_NTASKS}_OMP-${SLURM_CPUS_PER_TASK}_JOBID-${SLURM_JOBID}"
mkdir $dirdest
mv slurm-${SLURM_JOBID}.out $dirdest/
```

Variáveis de ambiente do SLURM

Alguns exemplos:

SLURM_JOB_PARTITION
SLURM_NNODES
SLURM_NTASKS
SLURM_NTASKS_PER_NODE
SLURM_CPUS_PER_TASK
SLURM_JOBID
SLURM_JOB_NODELIST
SLURM_SUBMIT_DIR

Exemplo: NAS Parallel Benchmark (BT-MZ)

```
$ sbatch BULL_srun_openmpi.sh bt-mz W
Submitted batch job 105539
$ squeue -u $USER
             JOBID PARTITION     NAME     USER ST       TIME  NODES NODELIST(REASON)
            105539 treinamen NPB_BT-M professo  R       0:05      1 sdumont5000

$ ls bt-mz_W_MPI-1_OMP-1_JOBID-105539/
slurm-105539.out    --> arquivo gerado pelo SLURM com a saída da aplicação

$ sbatch -N2 -n2 -c1 ./BULL_srun_openmpi.sh bt-mz W
Os parâmetros por linha de comando têm precedência sobre os definidos no script

$ ls bt-mz_W_MPI-2_OMP-1_JOBID-105540
slurm-105540.out
```

`scontrol`: alterando parâmetro do job

```
--dependency (-d): adia o início do job até que a dependência especificada seja satisfeita

$ sbatch BULL_srun_openmpi.sh bt-mz A
Submitted batch job 105558
$ sbatch -d afterany:105558 BULL_srun_openmpi.sh bt-mz A
Submitted batch job 105559
$ sbatch -d afterany:105559 BULL_srun_openmpi.sh bt-mz A
Submitted batch job 105560
$ sbatch -d afterany:105560 BULL_srun_openmpi.sh bt-mz A
Submitted batch job 105561
$ squeue -u $USER
             JOBID PARTITION     NAME     USER ST       TIME  NODES NODELIST(REASON)
            105559 treinamen NPB_BT-M professo PD       0:00      1 (Dependency)
            105560 treinamen NPB_BT-M professo PD       0:00      1 (Dependency)
            105561 treinamen NPB_BT-M professo PD       0:00      1 (Dependency)
            105558 treinamen NPB_BT-M professo  R       0:26      1 sdumont5000
```

`scontrol:` alterando parâmetro do job

```
$ scontrol show jobid 105561
JobId=105561 JobName=NPB_BT-MZ
   UserId=professor(63001) GroupId=treinamento(61052)
   Priority=1791 Nice=0 Account=treinamento QOS=normal
   JobState=PENDING Reason=Dependency Dependency=afterany:105560
   Requeue=1 Restarts=0 BatchFlag=1 Reboot=0 ExitCode=0:0
   RunTime=00:00:00 TimeLimit=00:05:00 TimeMin=N/A
   SubmitTime=2017-07-30T17:42:04 EligibleTime=Unknown
   StartTime=Unknown EndTime=Unknown
   PreemptTime=None SuspendTime=None SecsPreSuspend=0
   Partition=treinamento AllocNode:Sid=sdumont14:19952
   ReqNodeList=(null) ExcNodeList=(null)
   NodeList=(null)
   NumNodes=1-1 NumCPUs=1 CPUs/Task=1 ReqB:S:C:T=0:0:*:1
   Socks/Node=* NtasksPerN:B:S:C=1:0:*:* CoreSpec=*
   MinCPUsNode=1 MinMemoryNode=0 MinTmpDiskNode=0
   Features=(null) Gres=(null) Reservation=(null)
   Shared=0 Contiguous=0 Licenses=(null) Network=(null)
```

`scontrol`: alterando parâmetro do job

```
$ scontrol update JobId=105561 Partition=treinamento_gpu
$ scontrol show jobid 105561
JobId=105561 JobName=NPB_BT-MZ
   UserId=professor(63001) GroupId=treinamento(61052)
   Priority=1791 Nice=0 Account=treinamento QOS=normal
   JobState=PENDING Reason=Dependency Dependency=afterany:105560
   Requeue=1 Restarts=0 BatchFlag=1 Reboot=0 ExitCode=0:0
   RunTime=00:00:00 TimeLimit=00:05:00 TimeMin=N/A
   SubmitTime=2017-07-30T17:42:04 EligibleTime=Unknown
   StartTime=Unknown EndTime=Unknown
   PreemptTime=None SuspendTime=None SecsPreSuspend=0
   Partition=treinamento_gpu AllocNode:Sid=sdumont14:19952
   ReqNodeList=(null) ExcNodeList=(null)
   NodeList=(null)
   NumNodes=1-1 NumCPUs=1 CPUs/Task=1 ReqB:S:C:T=0:0:*:1
   Socks/Node=* NtasksPerN:B:S:C=1:0:*:* CoreSpec=*
   MinCPUsNode=1 MinMemoryNode=0 MinTmpDiskNode=0
   Features=(null) Gres=(null) Reservation=(null)
   Shared=0 Contiguous=0 Licenses=(null) Network=(null)
```

SLURM: comandos básicos

- **sinfo:** visualiza informação sobre os nós e partições do SLURM
- **squeue:** visualiza informação sobre o status dos jobs e escalonamento
- **srun:** alocação de recursos e distribuição de tarefas
- **scontrol:** ferramenta para visualizar e/ou modificar o estado de um job
- **salloc:** obtém uma alocação para o job
- **sbatch:** submete um script para alocação em uma partição do SLURM
- **scancel:** cancela um job
- **sacct:** mostra informação de jobs já submetidos

`sacct:` mostra informação de jobs já submetidos

```
$ sacct
158796            mpirun treinamen+ treinamen+          1     FAILED      1:0
158798            mpirun treinamen+ treinamen+          2  COMPLETED      0:0
158798.0           orted             treinamen+          2  COMPLETED      0:0
158802       bt-mz.A.2 treinamen+ treinamen+          2 CANCELLED+      0:0
158803       bt-mz.A.2 treinamen+ treinamen+          2  COMPLETED      0:0
158804       bt-mz.W.2 treinamen+ treinamen+          2  COMPLETED      0:0
158809            mpirun treinamen+ treinamen+          2  COMPLETED      0:0
158809.0           orted             treinamen+          2  COMPLETED      0:0
158810       bt-mz.W.2 treinamen+ treinamen+          2  COMPLETED      0:0
158811       bt-mz.W.2 treinamen+ treinamen+          2  COMPLETED      0:0
```

`sacct:` mostra informação de jobs já submetidos

```
$ sacct -j 158811
       JobID    JobName  Partition    Account  AllocCPUS      State ExitCode
------------ ---------- ---------- ---------- ---------- ---------- --------
158811        bt-mz.W.2 treinamen+ treinamen+          2  COMPLETED      0:0
```

`sacct:` mostra informação de jobs já submetidos

```
$ sacct -e
AllocCPUS           AllocGRES           Account             AssocID
AveCPU              AveCPUFreq          AveDiskRead         AveDiskWrite
AvePages            AveRSS              AveVMSize           BlockID
Cluster             Comment             ConsumedEnergy      ConsumedEnergyRaw
CPUTime             CPUTimeRAW          DerivedExitCode     Elapsed
Eligible            End                 ExitCode            GID
Group               JobID               JobIDRaw            JobName
Layout              MaxDiskRead         MaxDiskReadNode     MaxDiskReadTask
MaxDiskWrite        MaxDiskWriteNode    MaxDiskWriteTask    MaxPages
MaxPagesNode        MaxPagesTask        MaxRSS              MaxRSSNode
MaxRSSTask          MaxVMSize           MaxVMSizeNode       MaxVMSizeTask
MinCPU              MinCPUNode          MinCPUTask          NCPUS
NNodes              NodeList            NTasks              Priority
Partition           QOS                 QOSRAW              ReqCPUFreq
ReqCPUS             ReqGRES             ReqMem              Reservation
ReservationId       Reserved            ResvCPU             ResvCPURAW
Start               State               Submit              Suspended
SystemCPU           Timelimit           TotalCPU            UID
User                UserCPU             WCKey               WCKeyID
```

`sacct:` mostra informação de jobs já submetidos

```
$ sacct -j 158811 --format=JobID,JobName,Elapsed,NodeList
       JobID    JobName    Elapsed        NodeList
------------ ---------- ---------- ---------------
158811        bt-mz.W.2   00:00:04     sdumont5000
```